

Titel der Abschlussarbeit

Bachelorarbeit
von
Marius Wodtke

an der Fakultät für Informatik

In dem Studiengang
Informatik (B.Sc.)

eingereicht am 01.01.01 beim
Institut für Angewandte Informatik
und Formale Beschreibungsverfahren
des Karlsruher Instituts für Technologie

Referent: Prof. Dr. Hartmut Schmeck

Betreuer: Kaibin Bao

KIT – Universität des Landes Baden-Württemberg und
nationales Forschungszentrum in der Helmholtz-Gemeinschaft

Eidesstattliche Erklärung

Ich versichere hiermit wahrheitsgemäß, die Arbeit und alle Teile daraus selbständig angefertigt, alle benutzten Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderung entnommen wurde.

Karlsruhe, den DATUM

NAME

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Fragestellung	1
1.3	Weiterer Aufbau	2
2	Datensatz	3
2.1	Gemessene Daten	3
2.2	Berechnete Daten	4
2.3	Die Waschmaschine	4
3	Vorverarbeitung	7
3.1	Stand der Technik	7
3.2	Extrahieren der Daten	8
3.3	Zeitreihen	8
3.4	Spezielle Features	8
4	Klassifizierung	10
4.1	Stand der Technik	10
4.2	Weka	10
4.3	Parameter	10
5	Evaluation	12
5.1	Einleitung	12
5.2	Tabellensammlung	12
6	Fazit	15
A	Anhang	16

Abkürzungsverzeichnis

NILM	Non-intrusive load monitoring
KNN	Künstliches Neuronale Netz
ESHL	Energy Smart Home Lab
MLP	Multi Layer Perceptron

Abbildungsverzeichnis

1	Typischer Waschgang, farbig annotiert	6
---	---	---

Tabellenverzeichnis

1	Übersicht Gerätezuordnung	3
2	Format ESHL Daten	3
3	Übersicht Trainingsdaten	5
4	Genauigkeit der Zeitreihen Features	13
5	Parameteränderungen beste Zeitreihe	13
6	Spezielle Features	14
7	Konfusionsmatrix	14

1 Einleitung

1.1 Motivation

Energie zu sparen ist seit Langem ein Ziel der Umweltpolitik, dennoch steigt der Energieverbrauch in Industrieländern kontinuierlich und es werden nach wie vor Wege gesucht, diesen zu senken. In den USA verursachen private Haushalte 40% des CO₂-Ausstoßes [VBG08] und stehen deshalb im Fokus vieler Programme zum Energiesparen.

Je nach Studie besteht für die Haushalte ein Einsparungspotential von bis zu 20% [AGSA13], Fischer [Fis08] untersucht mehrere dieser Studien und beschreibt ein durchschnittliches Einsparungspotential von 5-12%. Um dieses Einsparungspotential auszunutzen, muss der Nutzer regelmäßig und möglichst genau über seinen Verbrauch aufgeklärt werden. Er kann sich oft nicht mit seinem Verbrauch identifizieren, weil dieser intransparent und durch die langen Rechnungsintervalle nicht präsent ist.

Damit der Nutzer anfängt sich selbst zu kontrollieren, muss er begreifen, dass sich sein Verhalten auf seinen Verbrauch auswirkt und er ihn auch durch die gezielte Veränderungen seines Handelns senken kann [Fis08].

Non-intrusive load monitoring (NILM) bietet nun die Chance dem Nutzer eine regelmäßige, detaillierte Rückmeldung zu seinem Energiekonsum zu geben, Kolter und Matthew [KJ11] beschreibt NILM als die Aufgabe aus einem, für den gesamten Haushalt messenden Stromzähler, Rückschlüsse über die elektrische Last einzelner Geräte zu ziehen. Ein solches System wird dem Konsumenten helfen, verschwenderische Verhaltensweisen und Geräte zu identifizieren ohne den Haushalt mit vielen digitalen Zählern für die individuellen Geräte ausrüsten zu müssen, wie es derzeit z.B. mit sogenannten *Energiekostenmessgeräten* auf Steckerbasis praktiziert wird.

1.2 Fragestellung

Viele Systeme zur Disaggregation oder zu verschiedenen Vorhersage-Aufgaben benutzen Ansätze des Maschinellen Lernens. Sie benötigen annotierte (gelabelte) Trainingsdaten, um robuste Modelle zu erzeugen. Annotieren bedeutet in diesem Zusammenhang, die Daten mit Metadaten wie etwa dem Gerätezustand zu versehen. Mehr Trainingsdaten führen in der Regel zu besseren Modellen, die Annotation ist allerdings sehr aufwändig, weil sie manuell erfolgen muss. Der Ansatzpunkt dieser Arbeit ist, das Problem der Disaggregation auf ein Gerät zu reduzieren und so zu vereinfachen. Nun kann man ein robustes Modell mit nur wenigen Trainingsdaten erstellen und mit diesem dann eine große Menge an Daten schnell annotieren. Diese gelabelten Daten sollen dann wiederum als Trainingsdaten für schwierigere Aufgaben verwendet werden. Aufgabe dieser Bachelorarbeit ist es ein

System zu entwickeln, welches in der Lage ist die Zustände von ausgewählten Geräten in einem disaggregierten Lastgang zu klassifizieren und so eine Segmentierung für diese Geräte zu erstellen. Dies beinhaltet sowohl die nötige Vorverarbeitung der Daten sowie eventuelle nachträgliche Formatierungen. Die eigentliche Klassifikation soll mit Künstlichen Neuronalen Netzen (KNN) stattfinden, dabei sollte eine möglichst hohe Akkuratität erreicht werden, da Systeme, die mit den resultierenden Daten trainiert werden keine Möglichkeit haben Fehler, die bereits in den Trainingsdaten sind, zu korrigieren.

1.3 Weiterer Aufbau

Im folgenden Kapitel 2 werden die verwendeten, disaggregierten Energiedatensätze beschrieben. Insbesondere werden die gemessenen Werte und die daraus berechenbaren Werte untersucht. Kapitel 3 gibt zunächst einen Überblick über die aktuelle Forschung im Bereich Vorverarbeitung der Daten und Feature-Auswahl, anschließend werden die für diese Arbeit verwendeten Vorverarbeitungsschritte und Features erläutert. In Kapitel 4 soll schließlich die eigentliche Klassifizierung beschrieben werden, hier werden insbesondere das verwendete Netz und die Trainingsmethoden besprochen. Auch hier wird es einen kurzen Überblick über die aktuelle Forschung geben. In Kapitel 5 findet die Klassifikation statt, hier werden verschiedene Klassifizierungsaufgaben ausgeführt und ausgewertet. Am Schluss steht das Fazit, in dem die Ergebnisse zusammengefasst und mit ursprüngliche Fragestellung verglichen werden.

2 Datensatz

Die verwendeten Daten stammen aus dem *KIT Energy Smart Home Lab (ESHL)*. Das ESHL ist ein $60m^2$ Apartment mit intelligenten Haushaltsgeräten und soll einen möglichen zukünftigen Haushalt simulieren. Die Daten des ESHL wurden über fast 3 Jahre zwischen dem 22.08.2011 und dem 31.07.2014 aufgezeichnet, weisen aber einige Lücken auf. Für die Messungen wurden mehrere Smart Meter verwendet, bei Großverbrauchern wie etwa dem Boiler wurden dabei alle drei Phasen gemessen, sie sind durch die Nummer des Smart Meters in den Daten identifizierbar. Bei den restlichen Geräten wurde nur je eine Phase gemessen, das heißt, dass je 3 Geräte an einem Smart Meter angeschlossen sind. Sie sind durch die Nummer des Smart Meters in Kombination mit Nummer des verwendeten Ports identifizierbar. Wie viele Phasen zur Messung eines Geräts verwendet wurden lässt sich dem Controller entnehmen.

UUID	Name	Klassifikation	Controller	Meter	Port
...-5602c0a80114	DRYER	APPLIANCE	1	3	0
...-5604c0a80114	WASHINGMACHINE	APPLIANCE	1	7	2

Tabelle 1: Beispiele für Gerätezuordnung, die Waschmaschine ist an (Smart-)Meter 7 Port 2 angeschlossen.

2.1 Gemessene Daten

Die Daten des *KIT Energy Smart Home Lab* besitzen folgendes Format.

Unixtime	UUID	Con- troller	Meter	Port	Span- nung	Strom- stärke	Wirk- leistung	Wirkl. aggregiert
1382291846	...-5604c0a80114	1	7	2	218.5	8.96	1956	145550
1315269463	...-5602c0a80114	1	3	0	223.8	13.16	2950	38300
1315269465	...-5602c0a80114	1	3	0	223.9	12.5	2796	38300

Tabelle 2: Format ESHL Datensatz.

Controller, Meter und Port werden, wie oben beschrieben, verwendet, um einen Datenpunkt einem eindeutigen Gerät zuzuordnen. Hier ist zu beachten, sich diese Werte immer nur gemeinsam verwendet werden dürfen. Die Spalte mit der UUID-Zuordnung wird ignoriert, denn sie enthält ebenfalls die Information um welches Gerät es sich handelt und ist somit Redundant zu Controller, Meter und Port.

Ein Datenpunkt enthält die gemessene Spannung, die Stromstärke und die Wirkleistung. Es wird zusätzlich die aggregierte Wirkleistung gemessen, welche aber zunächst ignoriert wird, da sie sich aus der Wirkleistung berechnen lässt.

Eine Besonderheit stellt das Aufzeichnungsintervall dar. Die Smart Meter erzeugen jede Sekunde einen neuen Datenpunkt für jeden Port, dieser wird aber nur gespeichert, wenn sich die Wirkleistung im Vergleich zum letzten gespeicherten Punkt um 5 Watt Wirkleistung unterscheidet. So werden insbesondere lange *Off* Phasen auf einen Datenpunkt komprimiert, es gehen aber auch kleinere Schwankungen in der Wirkleistung von sehr verbrauchsarmen Geräten verloren.

2.2 Berechnete Daten

Die Messung von Spannung und Stromstärke erlaubt es eine Vielzahl von Energiewerten zu berechnen, in diesem Abschnitt werden die Schein- und Blindleistung vorgestellt, das Kapitel zur Vorverarbeitung wird zusätzlich eine Form der Normalisierung vorstellen. Die Scheinleistung ist das Produkt aus Spannung und Stromstärke und ist die gesamte, aus dem Netz gezogene Leistung:

$$\textit{Scheinleistung} = \textit{Spannung} * \textit{Stromstärke}$$

Zur Berechnung der Blindleistung werden Schein- und Wirkleistung genutzt, die Blindleistung ist dabei Leistung, die aus dem Netz gezogen wird ohne tatsächlich genutzt zu werden:

$$\textit{Blindleistung} = \sqrt{\textit{Scheinleistung}^2 - \textit{Wirkleistung}^2}$$

2.3 Die Waschmaschine

Die Waschmaschine ist ein besonders interessantes Gerät für die Klassifikation, denn sie hat nicht nur einen *On*- und einen *Off-Zustand*, sondern einen Motor, der mit verschiedenen Drehzahlen laufen kann, ein Heizelement und eine Pumpe. Für die Waschmaschine existieren außerdem einige annotierte Waschgänge die als Trainingsdaten verwendet werden können.

Die Waschgänge sind mit sechs verschiedenen Klassen Sigma 0 bis Sigma 5 annotiert, Sigma 0 ist der *Off-Zustand*. Sigma 1 ist ein normaler Schleudervorgang, hier sind Phasen mit 200-350 Watt und dazwischen kurze Pausen mit ca. 4 Watt Verbrauch typisch. Sigma 2 ist ein Heizvorgang, dieser kennzeichnet sich durch einen Verbrauch über 1700 Watt. Sigma 3 und Sigma 4 sind Pumpvorgänge und werden durch Verbrauchspitzen von wenigen

Profil	Startzeit (Unix)	Endzeit (Unix)	Dauer (Sekunden)	Datum
Profil 0	1382290611	1382296244	5633	20.10.2013
Profil 1	1382363246	1382369468	6222	21.10.2013
Profil 4	1382900551	1382905960	5409	27.10.2013
Profil 5	1383173215	1383180425	7210	30.10.2013
Profil 8	1384066710	1384072260	5550	10.11.2013

Tabelle 3: Übersicht über die annotierten Waschgänge, die als Trainingsdaten verwendet werden.

Sekunden charakterisiert. Unterschieden werden sie anhand der Höhe der Spitze, ein Vorgang Sigma 4 folgt immer auf einen Vorgang Sigma 3 mit einem Abstand von 50 bis 80 Sekunden. Sigma 5 ist das Ausschleudern, es ist ebenfalls ein Schleudervorgang, der aber im Gegensatz zu Sigma 1 ohne Pausen ausgeführt wird.




Abbildung 1: Ein typischer Waschgang, je nach Klasse wird die Wirkleistung in unterschiedlichen Farben dargestellt.

3 Vorverarbeitung

3.1 Stand der Technik

Die Wirkleistung ist das ursprünglichste Merkmal um die Zustände von Geräten zu unterscheiden. Sie gibt die elektrische Leistung an, die von einem Gerät in andere Leistungen (z.B. Wärme oder Bewegung) umgewandelt werden kann. Oft wird die Wirkleistung durch gröbere Quantisierung oder Normalisierung geglättet, um die Erkennung der Klassen zu vereinfachen. [Har92] verwendet hierzu folgende Formel:

$$P_{norm}(t) = \left(\frac{Nennspannung}{V(t)}\right)^2 * P(t)$$

mit $P :=$ Wirkleistung in Watt und $V :=$ Spannung in Volt, die Nennspannung beträgt in Europa 230 Volt.

Die Normalisierung bietet den Vorteil, dass sie nicht verlustbehaftet ist und wird deshalb häufig verwendet, wenn die Spannung gemessen wurde.

Mit der Wirkleistung allein ist man jedoch nicht in der Lage Geräte mit sehr ähnlichem Verbrauch zu unterscheiden, ein Beispiel wären hier ein 2kW Motor und ein 2kW Heizelement. Diese lassen sich mit Hilfe der Blindleistung, welche nicht in andere Leistungen umgewandelt wird, unterscheiden, weil der Motor als induktiver Verbraucher mehr Blindleistung als das Heizelement aus dem Stromnetz zieht. Nachteil hier ist jedoch, dass die Blindleistung (und auch die Spannung) zusätzlich gemessen werden muss, die Berücksichtigung dieses Features kostet also gegebenenfalls Geld [ZR11].

Vergleicht man jedoch eine 60W Glühbirne und einen Laptop mit einem 60W Netzteil, dann stellt man fest, dass diese sich auch unter Hinzunahme der Blindleistung kaum unterscheiden lassen [LLC⁺03]. Hier hilft die Betrachtung von micro level Features. Dabei werden die Wellenformen und die harmonischen Komponenten des Frequenzspektrums verwendet, um Verbraucher zu unterscheiden. Laughman et al. [LLC⁺03] zeigen z.B., dass sich Glühbirne und Netzteil in der 3. harmonischen Komponente deutlich unterscheiden. Zusätzlich verändern viele Geräte die Wellenform des Stroms, so dass in diesem Bereich weiteres Potential für die Unterscheidung verschiedener Geräte vorliegt [LNKC10].

Micro level Features bieten sehr gute Unterscheidungsmöglichkeiten, benötigen aber auch ein sehr hochfrequent aufgelöstes Signal, üblich sind mehrere kHz. Anderson et al. [AOB⁺12] bietet einen Datensatz mit 12kHz Auflösung.

Messgeräte für eine solche Auflösung sind wesentlich teurer als die häufig für Wirk- und Blindleistung verwendeten Geräte mit einer Auflösung von 1Hz und sind im Gegensatz zu Letzteren oft nicht in normalen Haushalten mit Smartmeter vorhanden [ZR11].

Da sie in der Praxis häufiger vorhanden sind, wird in dieser Thesis mit den macro level

Features mit einer Auflösung von 1Hz gearbeitet.

3.2 Extrahieren der Daten

Da die Trainingsdaten leider nur die Wirkleistung zum aktuellen Zeitpunkt angeben, müssen diese erneut aus dem gesamten Datensatz herausgezogen werden. Zunächst wird der Datensatz mit $\text{Meter} = 7$ und $\text{Port} = 2$ gefiltert und so die Waschmaschine ausgewählt. Anschließend werden die Startzeiten der einzelnen Waschgänge über ihre Heizphase gesucht und mit Hilfe der Länge des Waschganges der zu filternde Abschnitt für jedes Profil bestimmt. Hat man diese nun herausgefiltert, hat man neben der Wirkleistung zusätzlich Spannung, Stromstärke und aggregierte Wirkleistung zur Verfügung. Dies ist wichtig um z.B. die normalisierte Wirkleistung zu berechnen.

3.3 Zeitreihen

Da sich die Klassen der Waschmaschine zum Teil überschneiden ist eine fehlerfreie Klassifizierung nur mit Hilfe der Wirkleistung zum aktuellen Zeitpunkt ausgeschlossen. Dies fällt insbesondere bei Klasse 3 und 4 auf, ihre Flanken fallen oft in den selben Wertebereich, nur ihre Spitzen sind klar unterschiedlich.

Eine Möglichkeit diese mit einzubeziehen ist die zusätzliche Verwendung von vergangenen und zukünftigen Werten für die Wirkleistung. Diese Arbeit verwendet zunächst eine Umgebung von 10 Sekunden, also die Werte der Wirkleistung von $t - 10$ bis $t + 10$ für einen in Sekunden angegebenen Zeitpunkt t .

Zu beachten ist die spezielle Komprimierung der Daten des ESHL. Zur einfacheren Verarbeitung werden diese zunächst wieder auf sekundliche Daten erweitert und anschließend die Werte der Wirkleistung der vorherigen und nächsten 10 Sekunden angehängt. Dies erlaubt eine Verarbeitung auch außerhalb der zeitlichen Reihenfolge mit nur einer einzigen Zeile dieses neuen Datensatzes.

Nachteil ist die nötige Kenntnis zukünftiger Werte, dies verhindert eine live Klassifizierung. Nutzt man den Wert $t + 10$ hängt der Klassifikator der Gegenwart immer mindestens 10 Sekunden nach, dies sollte zur Erstellung großer, annotierter Datensätze jedoch keine Rolle spielen.

3.4 Spezielle Features

Neben der Möglichkeit auf die Fähigkeit der Generalisierung des KNNs zu vertrauen und diesem einfach die Zeitreihe zu präsentieren, besteht auch die Möglichkeit ihm neben der Wirkleistung zum aktuellen Zeitpunkt noch weitere, speziell für die Waschmaschine

berechnete Features zu präsentieren.

Für die Unterscheidung von Klasse 3 und 4 lässt sich die Verbrauchsspitze in den umgebenden 10 Sekunden berechnen um diese klar trennen zu können. Um Klasse 4 von Klasse 5 zu trennen kann man sich den Durchschnitt der folgenden Sekunden anschauen, dieser sollte bei einem Punkt der Klasse 5 deutlich höher liegen als bei Klasse 4. Die dritte schwierige Unterscheidung ist die von Klasse 1 und 5, hier hilft es sich das Minimum der vorhergehenden Werte anzusehen, Klasse 1 weist hier durch die Pausen Werte von ca. 4 Watt auf, während Klasse 5 Werte über 200 Watt haben sollte. Alle anderen Klassenunterscheidungen sollten sich mit Hilfe der Wirkleistung treffen lassen.

Zusätzlich zur Verwendung von Zukunftswerten weist diese Auswahl an Features den Nachteil auf, nur für diese Waschmaschine explizit zu sein, für andere Geräte müssten gegebenenfalls neue Features gefunden werden, dies erhöht den zeitlichen Aufwand, der zur Klassifizierung eines kompletten Datensatzes nötig ist, enorm.

4 Klassifizierung

4.1 Stand der Technik

4.2 Weka

Weka ist ein bekanntes Framework für maschinelles Lernen. Die in Java geschriebene Software wurde von der *University of Waikato, New Zealand* entwickelt und unter *GNU General Public License* veröffentlicht.

Weka bietet viele, für diese Arbeit wichtige, Features an. Insbesondere die integrierten Filter und die automatische Interpretation von Instanzen zur Klassifikation ersparen viel Arbeit. Weka implementiert eine Vielzahl von Klassifikatoren, darunter auch das Multilayer Perceptron (MLP). Außerdem bietet es einige Methoden zur Evaluation der erstellten Modelle, wie zum Beispiel die k-fold-Evaluierung. Dabei ist es jedoch nicht auf die massiv parallele Verarbeitung moderner Prozessoren ausgelegt und ist deshalb recht langsam.

Diese Arbeit benutzt Wekas Implementierung des MLP wegen der einfachen Verwendung und trotzdem guten Einstellbarkeit des Netzwerks. Außerdem verringern die bereits implementierten Funktionen zur Filterung und Evaluation den Aufwand für die hier erstellte Software enorm.

4.3 Parameter

Ein MLP hat einige wichtige Parameter, die zur Genauigkeit der Klassifikation beitragen. Dieses Kapitel soll aber lediglich auf die Parameter hinweisen, die besten besten Werte für jeden Parameter wird das Kapitel der *Evaluation* suchen. Mit dem ersten wichtigen Parameter hat sich bereits das vorherige Kapitel beschäftigt: Die Features. Diese spielen in der Klassifikation eine zentrale Rolle und wurden daher gesondert behandelt.

Die Anzahl der Epochen (N) gibt an, wie oft das Netz die Trainingsinstanzen während des Trainings durchläuft. Bei jedem Durchlauf wird der vom Netz verursachte Fehler mit dem Backpropagation Algorithmus minimiert. Ist die Anzahl der Epochen zu gering, kann der Fehler nicht ausreichend minimiert werden.

Die Geschwindigkeit, mit der die Gewichte innerhalb des Netzes angepasst und somit der Fehler minimiert wird, wird durch die Lernrate (L) bestimmt. Eine höhere Lernrate führt dazu, dass das Netz schneller in Richtung des lokalen Optimums konvergiert, kann aber auch dazu führen, dass es das Optimum überspringt und es nie genau erreicht. Dies kann aber durchaus erwünscht sein, wenn eine sehr niedrige Lernrate zu einem lokalen Optimum konvergiert, das deutlich unter dem, von einer höheren Lernrate gefundenen Maximum liegt. Außerdem benötigt eine niedrige Lernrate im Allgemeinen mehr Epochen um das

lokale Optimum zu erreichen.

Um sich möglichst dem globalen Maximum anzunähern ist das Momentum (M) hilfreich. Dieses erhöht die Lernrate, wenn sich der Fehler verringert und senkt diese, wenn der Fehler nicht mehr sinkt. Dies sorgt dafür, dass das Netz nicht optimale, lokale Maxima leichter überspringt und sich anschließend mit einer kleineren Lernrate dem Hochpunkt des gefundenen Maximums annähert.

Auch die Struktur des Netzes (H) kann einen positiven Einfluss auf die Klassifikation haben. Dabei sind Eingabe- und Ausgabeschicht (input-/outputlayer) im Allgemeinen festgeschrieben, der inputlayer hat so viele Knoten wie es Features gibt und der outputlayer so viele Knoten wie es Klassen gibt. Die versteckten Schichten (hiddenlayer) dazwischen sind aber variabel, hier ist es üblich mit einer Schicht zu beginnen und diesem eine Knotenanzahl zwischen den Knotenzahlen des input- und outputlayers zuzuweisen. Danach kann man testen, ob sich das Hinzufügen weiterer hiddenlayer positiv auf die Fehlerrate auswirkt.

5 Evaluation

5.1 Einleitung

5.2 Tabellensammlung

Zu Beginn beschäftigen wir uns mit der Auswahl des richtigen Zeitfensters. Es zeigt sich schnell, dass selbst dieser begrenzte Feature-Raum bereits mehrere lokale Optima aufweist. Die besten Ergebnisse liefert der Zeitraum von 3 Sekunden um den Zeitpunkt t , für diesen werden weitere Tests durchgeführt.

Zunächst variieren wir die Epochen N . Festzustellen ist, dass eine Erhöhung der Epochen über 1000 keine Verbesserung der Genauigkeit mehr mit sich bringt. Die Normalisierung der Wirkleistung verschlechtert das Ergebnis. Dies ist vermutlich auf die vorherige Quantisierung der Daten zurückzuführen, diese sorgt dafür, dass die Normalisierung die Werte eher streut statt glättet.

Das Hinzufügen eines zweiten hidden layer führt zu einer Verbesserung der Klassifikationsgenauigkeit. Die Veränderung von Lernrate und Momentum beziehungsweise das Hinzufügen eines dritten hidden layer bringen jedoch keine weiteren Verbesserungen.

Die speziell für die Waschmaschine gesuchten Features schneiden schlechter als die Zeitreihen ab. Dies soll kein großer Rückschlag für diese Arbeit sein, die Zeitreihen sind leichter zu berechnen und besitzen allgemeineren Charakter. Letztere Eigenschaft scheint nicht nur praktisch, sondern auch der Klassifikation dienlich zu sein.

Ein genauerer Blick auf die Konfusionsmatrix des Netzes mit dem besten Ergebnis verrät, dass die meisten Verwechslungen zwischen Klasse 3, 4 und 5 auftreten. Das Netz hat hier offenbar Probleme die Unterschiede in den Verbrauchsspitzen zu erkennen. Diese Art von Fehlern umfasst 62 Instanzen und somit knapp 2/3 der Fehlklassifikationen.

Die 22 Fehler bei denen ein *Off-Zustand* als Klasse 1 klassifiziert wurden sind im Prinzip *off-by-one-Fehler*. Das Netz erkennt nicht die semantische Bedeutung des Features $t+0$ und klassifiziert auch solche Zeitpunkte als *On-Zustand*, bei denen die Werte $t+1,2,3$ bzw. $b-1,2,3$ größer Null sind, obwohl $t+0$ gleich Null ist. Die restlichen Fehlklassifikationen sind ähnlich zu betrachten, insgesamt machen die *off-by-one-Fehler* mit 33 Instanzen gut 1/3 der Fehlklassifikationen aus.

Features	Korrekt klassifizierte Instanzen	Inkorrekt klassifizierte Instanzen	Genauigkeit
t-10 bis t+10	29263	740	97.5336%
t-9 bis t+9	29551	452	98.4935%
t-8 bis t+8	29652	351	98.8301%
t-7 bis t+7	29612	391	98.6968%
t-6 bis t+6	29372	631	97.8969%
t-5 bis t+5	29249	754	97.4869%
t-4 bis t+4	29802	201	99.3301%
t-3 bis t+3	29876	127	99.5767%
t-2 bis t+2	29093	910	96.967%
t-1 bis t+1	26526	3477	88.4112%
t+0	29508	495	98.3502%

Tabelle 4: Genauigkeit des Netzes bezüglich verschiedener Längen von Zeitreihen, Netz mit Weka Standardkonfiguration (-L 0.3 -M 0.2 -N 500 -H a)

Konfiguration	Normali- siert	Korrekt klassifi- zierte Instanzen	Inkorrekt klassifi- zierte Instanzen	Genauigkeit
-L 0.3 -M 0.2 -N 500 -H a	nein	29876	127	99.5767%
-L 0.3 -M 0.2 -N 500 -H a	ja	29870	133	99.5567%
-L 0.3 -M 0.2 -N 1000 -H a	nein	29888	115	99.6167%
-L 0.3 -M 0.2 -N 1000 -H a	ja	29882	121	99.5967%
-L 0.3 -M 0.2 -N 1500 -H a	nein	29883	120	99.6%
-L 0.3 -M 0.2 -N 1500 -H a	ja	29870	133	99.5567%
-L 0.3 -M 0.2 -N 1000 -H i,o	nein	29908	95	99.6834%
-L 0.2 -M 0.2 -N 1000 -H i,o	nein	29755	248	99.1734%
-L 0.4 -M 0.2 -N 1000 -H i,o	nein	29543	460	98.4668%
-L 0.3 -M 0.1 -N 1000 -H i,o	nein	29886	117	99.61%
-L 0.3 -M 0.3 -N 1000 -H i,o	nein	29540	463	98.4568%
-L 0.3 -M 0.3 -N 1000 -H i,o,i	nein	28368	1635	94.5505%

Tabelle 5: Genauigkeit des Netzes bezüglich verschiedener Parameter des Netzes, als Zeitreihe wird der Zeitraum t-3 bis t+3 verwendet, zusätzlich wird gegen die normalisierte Wirkleistung getestet

Konfiguration	Korrekt klassifizierte Instanzen	Inkorrekt klassifizierte Instanzen	Genauigkeit
-L 0.3 -M 0.2 -N 500 -H a	29535	486	98.3811%
-L 0.3 -M 0.2 -N 1000 -H a	29853	168	99.4404%
-L 0.3 -M 0.2 -N 1500 -H a	29535	486	98.3811%

Tabelle 6: Genauigkeit des Netzes bezüglich verschiedener Parameter des Netzes, es werden die speziellen Features verwendet

a	b	c	d	e	f	← classified as
3670	22	0	0	0	0	a = 0
0	20984	0	0	0	2	b = 1
0	2	4762	0	0	0	c = 2
0	3	0	39	15	0	d = 3
0	2	0	18	52	12	e = 4
0	2	0	0	17	401	f = 5

Tabelle 7: Konfusionsmatrix des Netzes mit den Features t-3 bis t+3 und den Parametern -L 0.3 -M 0.2 -N 1000 -H i,o

6 Fazit

A Anhang

Literatur

- [AGSA13] ARMEL, K CARRIE, ABHAY GUPTA, GIREESH SHRIMALI und ADRIAN ALBERT: *Is disaggregation the holy grail of energy efficiency? The case of electricity*. Energy Policy, 52:213–234, 2013.
- [AOB⁺12] ANDERSON, KYLE, ADRIAN OCNEANU, DIEGO BENITEZ, DERRICK CARLSON, ANTHONY ROWE und MARIO BERGES: *BLUED: A fully labeled public dataset for event-based non-intrusive load monitoring research*. In: *Proceedings of the 2nd KDD workshop on data mining applications in sustainability (SustKDD)*, Seiten 1–5, 2012.
- [Fis08] FISCHER, CORINNA: *Feedback on household electricity consumption: a tool for saving energy?* Energy efficiency, 1(1):79–104, 2008.
- [Har92] HART, GEORGE WILLIAM: *Nonintrusive appliance load monitoring*. Proceedings of the IEEE, 80(12):1870–1891, 1992.
- [KJ11] KOLTER, J ZICO und MATTHEW J JOHNSON: *REDD: A public data set for energy disaggregation research*. In: *Workshop on Data Mining Applications in Sustainability (SIGKDD), San Diego, CA*, Band 25, Seiten 59–62. Citeseer, 2011.
- [LLC⁺03] LAUGHMAN, CHRISTOPHER, KWANGDUK LEE, ROBERT COX, STEVEN SHAW, STEVEN LEEB, LES NORFORD und PETER ARMSTRONG: *Power signature analysis*. Power and Energy Magazine, IEEE, 1(2):56–63, 2003.
- [LNKC10] LIANG, JIAN, SIMON KK NG, GAIL KENDALL und JOHN WM CHENG: *Load signature study - Part I: Basic concept, structure, and methodology*. Power Delivery, IEEE Transactions on, 25(2):551–560, 2010.
- [VBG08] VANDENBERGH, MICHAEL P, JACK BARKENBUS und JONATHAN M GILLIGAN: *Individual carbon emissions: The low-hanging fruit*. UCLA Law Review, 55:08–36, 2008.
- [ZR11] ZEIFMAN, MICHAEL und KURT ROTH: *Nonintrusive appliance load monitoring: Review and outlook*. IEEE Transactions on Consumer Electronics, Seiten 76–84, 2011.